


DOKUMENTASI MACHINE LEARNING PERTEMUAN 6

Muhammad Ridho Irfani|231011402243

05TPLE017

Pertemuan 6 kali ini saya langsung melanjutkan dari pertemuan 5, jadi seperti berikut:

1. **Muat Data.** Pada langkah pertama, dilakukan pemisahan dataset menjadi data training, validation, dan testing menggunakan fungsi `train_test_split` dari library `scikit-learn`. sebelumnya parameter `stratify` digunakan untuk menjaga proporsi kelas, namun karena terdapat kelas yang hanya memiliki satu data, pemisahan secara stratified menyebabkan error. oleh karena itu, parameter `stratify` dihapus agar proses pembagian data tetap dapat dilakukan tanpa kendala.




```
EXPLORER  ...  pert5.ipynb  pert6.ipynb  Extension: jupyter
MACHINE_LEARNING
  .venv
  > etc
  > Include
  > Lib
  > Scripts
  > share
  pyenv.cfg
  .vscode
  kelulusan_mahasiswa...
  model.pkl
  pert4.ipynb
  pert5.ipynb
  pert6.ipynb
  processed_kelulusan...

pert6.ipynb > X_train, X_temp, y_train, y_temp = train_test_split(
Generate + Code + Markdown Run All Restart Clear All Outputs Jupyter Variables Outline ...

X_train, X_temp, y_train, y_temp = train_test_split(
    X, y, test_size=0.30, random_state=42
)
X_val, X_test, y_val, y_test = train_test_split(
    X_temp, y_temp, test_size=0.50, random_state=42
)
print(X_train.shape, X_val.shape, X_test.shape)

[4] ✓ 0.0s
... (7, 5) (1, 5) (2, 5)
```

2. **Pipeline & Baseline Random Forest.** Pada tahap ini dilakukan pelatihan model baseline menggunakan algoritma random forest. data dibagi menjadi data train, validation, dan test dengan proporsi 70:15:15. hasil evaluasi menunjukkan nilai F1-score = 1.0 pada data validasi, yang menandakan model mampu mengenali kelas dengan baik pada dataset kecil ini. namun, hasil ini belum bisa dijadikan tolok ukur performa akhir karena ukuran data validasi masih sangat kecil.



```
File Edit Selection View Go Run ... machine_learning
EXPLORER  ...  pert5.ipynb  pert6.ipynb  Extension: jupyter
MACH...  ...  ...
  .venv
  > etc
  > Include
  > Lib
  > Scripts
  > share
  pyenv.cfg
  .vscode
  kelulusan_mahasiswa...
  model.pkl
  pert4.ipynb
  pert5.ipynb
  pert6.ipynb
  processed_kelulusan...
  roc_test.png
  step7pert5.py

pert6.ipynb > from sklearn.pipeline import Pipeline
Generate + Code + Markdown Run All Restart Clear All Outputs Jupyter Variables Outline ...
pipe = Pipeline([
    ('pre', Preprocessor()),
    ('rf', RandomForestClassifier())
])
pipe.fit(X_train, y_train)


y_val_pred = pipe.predict(X_val)
print("Baseline RF - F1(val):", f1_score(y_val, y_val_pred, average="macro"))
print(classification_report(y_val, y_val_pred, digits=3))

[5] ✓ 2.4s
...
Baseline RF - F1(val): 1.0
      precision    recall  f1-score   support

0         1.000      1.000      1.000         1

accuracy          1.000
macro avg          1.000
weighted avg       1.000
```

3. **Validasi Silang.** parameter `n_splits` pada `StratifiedKFold` dikurangi menjadi 3 karena jumlah data pada tiap kelas tidak mencukupi untuk 5-fold cross-validation. hal ini dilakukan agar proses validasi tetap berjalan tanpa kehilangan proporsi data tiap kelas.



```
from sklearn.model_selection import StratifiedKFold, cross_val_score


skf = StratifiedKFold(n_splits=3, shuffle=True, random_state=42)
scores = cross_val_score(pipe, X_train, y_train, cv=skf, scoring="f1_macro", n_jobs=-1)
print("CV F1-macro (train):", scores.mean(), "±", scores.std())
```

[7] ✓ 8.2s

CV F1-macro (train): 1.0 ± 0.0

hasil cross-validation menghasilkan skor F1-macro 1.0 dengan deviasi 0.0, yang menunjukkan bahwa model memiliki performa sempurna dan konsisten di semua lipatan data pelatihan.

4. **Tuning Ringkas (GridSearch).** Pada tahap hyperparameter tuning menggunakan `GridSearchCV` dengan 3-fold cross-validation, model menghasilkan kombinasi parameter terbaik yaitu `max_depth=None` dan `min_samples_split=2`. hasil evaluasi menunjukkan nilai F1 pada data validasi sebesar 1.0, menandakan performa model yang sangat baik.



```
from sklearn.model_selection import GridSearchCV

param = {
    "clf__max_depth": [None, 12, 20, 30],
    "clf__min_samples_split": [2, 5, 10]
}

gs = GridSearchCV(pipe, param_grid=param, cv=skf,
                  scoring="f1_macro", n_jobs=-1, verbose=1)
gs.fit(X_train, y_train)
print("Best params:", gs.best_params_)
best_model = gs.best_estimator_
y_val_best = best_model.predict(X_val)
print("Best RF - F1(val):", f1_score(y_val, y_val_best, average="macro"))
```


[8] ✓ 14.7s

Fitting 3 folds for each of 12 candidates, totalling 36 fits

Best params: {'clf__max_depth': None, 'clf__min_samples_split': 2}

Best RF - F1(val): 1.0

5. **Evaluasi Akhir (Test Set).** Pada tahap evaluasi model menggunakan data uji, model menghasilkan nilai F1, precision, recall, dan ROC-AUC sebesar 1.0. hal ini menunjukkan bahwa model mampu melakukan klasifikasi dengan akurasi sempurna pada dataset uji.




	precision	recall	f1-score	support
0	1.000	1.000	1.000	1
1	1.000	1.000	1.000	1
accuracy			1.000	2
macro avg	1.000	1.000	1.000	2
weighted avg	1.000	1.000	1.000	2

Confusion Matrix (test):

```
[[1 0]
 [0 1]]
```

ROC-AUC(test): 1.0



6. **Pentingnya fitur.** Pada tahap ini dilakukan analisis untuk mengetahui fitur mana yang paling berpengaruh terhadap hasil prediksi. Hasil menunjukkan fitur IPK memiliki pengaruh paling besar, diikuti oleh IPK_x_Study, Waktu_Belajar_Jam, Rasio_Absensi, dan Jumlah_Absensi.

```

model.pkl
pert4.ipynb
pert5.ipynb
pert6.ipynb
pr_test.png
processed_kelulusan...
rf_model.pkl
roc_test.png
step7pert5.py
X_train.csv

for name, val in top[:10]:
    print(f"{name}: {val:.4f}")
except Exception as e:
    print("Feature importance tidak tersedia:", e)

# 6b) (Optional) Permutation Importance
# from sklearn.inspection import permutation_importance
# r = permutation_importance(final_model, X_val, y_val, n_repeats=10, random_state=42, n_jobs=-1)
# ... (urutkan dan laporkan)

[10] ✓ 0.0s

... Top feature importance:
num_IPK: 0.2483
num_IPK_x_Study: 0.2279
num_Waktu_Belajar_Jam: 0.2211
num_Rasio_Absensi: 0.1565
num_Jumlah_Absensi: 0.1463

```

7. **Simpan Model.** Model random forest yang telah dilatih disimpan ke dalam file rf_model.pkl. Langkah ini bertujuan agar model bisa digunakan kembali tanpa perlu pelatihan ulang.

```

kelulusan_mahasiswa....
model.pkl
pert4.ipynb
pert5.ipynb
pert6.ipynb
pr_test.png
processed_kelulusan....

import joblib
joblib.dump(final_model, "rf_model.pkl")
print("Model disimpan sebagai rf_model.pkl")

[11] ✓ 0.4s

... Model disimpan sebagai rf_model.pkl

```

8. **Cek Inference Lokal.** Model yang sudah disimpan kemudian diuji dengan data baru untuk memastikan fungsionalitasnya berjalan dengan baik. Hasil prediksi menunjukkan output 1, yang berarti mahasiswa diprediksi lulus.

```

model.pkl
pert4.ipynb
pert5.ipynb
pert6.ipynb

"IPK_x_Study": 3.4*7
})
print("Prediksi:", int(md1.predict(sample)[0]))

[12] ✓ 0.4s

... Prediksi: 1

```